# 大規模なデータ解析のためのUNIX入門

# SunGridEngine 利用方法

23/June/2017

情報管理解析室 西出 浩世



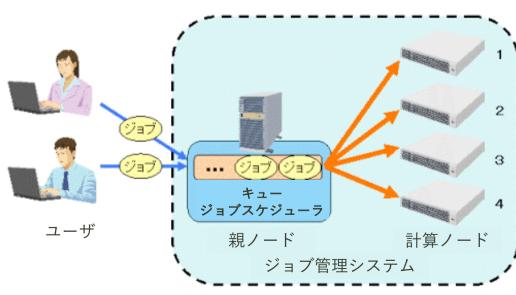
# ジョブ管理システム:SunGridEngine

複数の人間が同じ計算機群を使いたい・・・ どのマシン/CPUが空いてるか? どの計算を優先させるべきか?

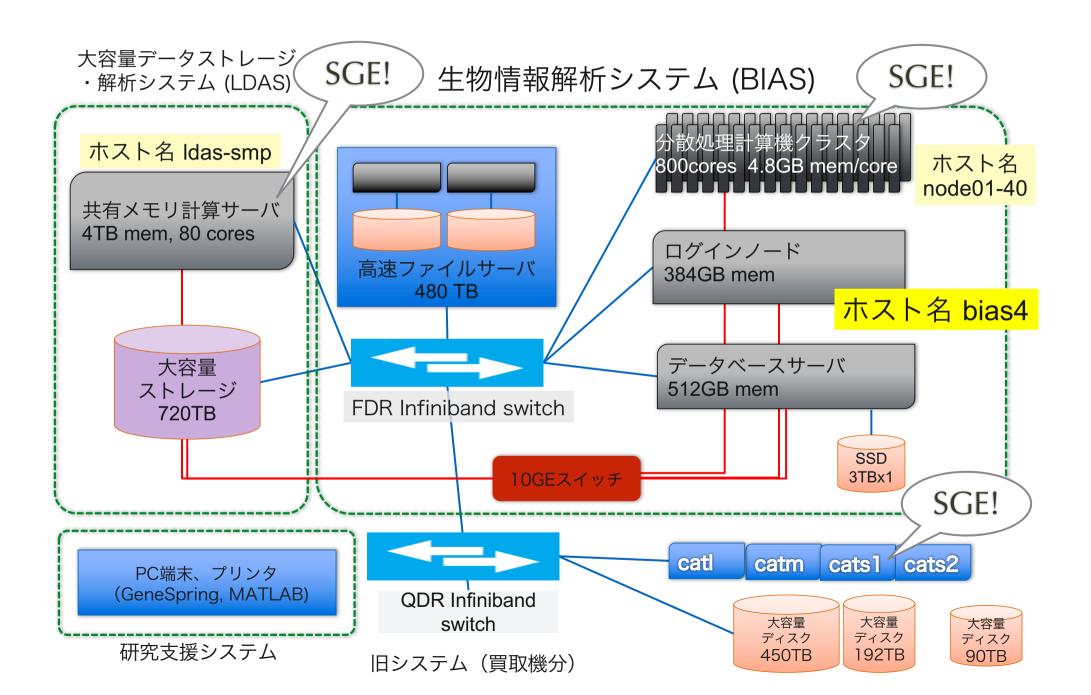
- ▶ 親ノードを設置し、ジョブ管理システムを運用
- ▶ 計算機資源の割り当てを自動で行い、効率を上げる

▶ ユーザは親ノードにジョブを投げるだけ(親ノードの名前すら知らなくてもよい)

SunGridEngine (SGE)



# 生物情報解析システムの構成



# 作業ディレクトリ

~/data/4\_sge

```
$ cd ~/data/4_sge
$ ls
bowtiel.sh ex.sh genome test_fastq
```

genome ディレクトリ、test\_fastq ディレクトリ内の内容を確認

```
$ ls genome
$ ls test_fastq
```

\* 解析結果を格納するディレクトリ「results」を作成する

```
$ mkdir results
```

# ジョブ管理システムの利用

- 実行したいコマンドをシェルスクリプト内に記述し、qsubコマンド (後述)を用いて実行させる
- シェルスクリプト ex.sh の中身を確認

```
$ less ex.sh
```

ex.sh

```
#!/bin/sh
path=~/data/4_sge
bowtie2 -x ${path}/genome/ecoli_genome
    -U ${path}/test_fastq/ecoli.1.fastq
    -S ${path}/results/ecoli.1.sam
```

~/data/4\_sge/rnaseq 内の ecoli.1.fastqファイルを、
 ~/data/4\_sge/genome にある ecoli\_genome にbowtie2 でマッピングし、結果は ~/data/4\_sge/results に保存

# SGE 実行コマンド qsub

- シェルスクリプトをジョブ管理システム(SGE)に投入:qsub
- qsub コマンドの引数にシェルスクリプト名を付けて実行
  - \$ qsub scriptname
- ex.sh をqsubコマンドで実行

# \$ qsub ex.sh Your job 814953 ("ex.sh") has been submitted ジョブ番号

- 投入されたジョブは番号が付けられ、ログインノードから分散処理 計算機クラスタ内のノードに送られて実行される
- 標準出力と標準エラー出力のログが<u>ホームディレクトリに</u>ファイル として作られる
  - ▶ シェルスクリプト名.oジョブ番号 (標準出力)
  - ▶ シェルスクリプト名.eジョブ番号 (標準エラー出力)

# qsub (ex.sh) 結果の確認

```
$ cd results
                                           結果ファイルの確認
$ 1s
ecoli.1.sam
                               標準出力・標準エラー出力ファイル
$ 1s ~/ex.sh.*
ex.sh.e814953 ex.sh.o814953
$ less ~/ex.sh.e814953
                             標準エラー出力ファイルの中身を確認
330118 reads; of these:
 330118 (100.00%) were unpaired; of these:
   3364 (1.02%) aligned 0 times
   229054 (69.39%) aligned exactly 1 time
   97700 (29.60%) aligned >1 times
98.98% overall alignment rate
$ less ecoli.sam
                                     結果ファイルの中身を確認
                                      作業ディレクトリに戻る
$ cd ..
```

## SGE その他コマンド

<b>qsub</b> script_filename	ジョブを投入			
qstat	自分のジョブの状態を表示			
qstat -u '*'	全ユーザのジョブ状態を表示			
<b>qdel</b> job-ID	ジョブを削除			

#### \$ qstat

#### \$ qdel 814953

hiroyo has deleted job 814953

# qsub のオプション

qsub には様々なオプションがあり、シェルスクリプト内で「#\$」に 続けて書いておくことで機能を加えることができる

```
$ less bowtie1.sh
```

bowtie1.sh

```
#!/bin/sh
#$ -q gitc gitcキューを指定
#$ -cwd qsubしたディレクトリに移動してジョブを実行

bowtie2 -x genome/ecoli_genome
-U test_fastq/ecoli.1.fastq
-S results/ecoli.1.sam
```

- -cwd を指定しているので、データ等を相対パスで書いている
- この場合標準出力・エラー出力ログも同じ場所にできる

# qsub の主なオプション

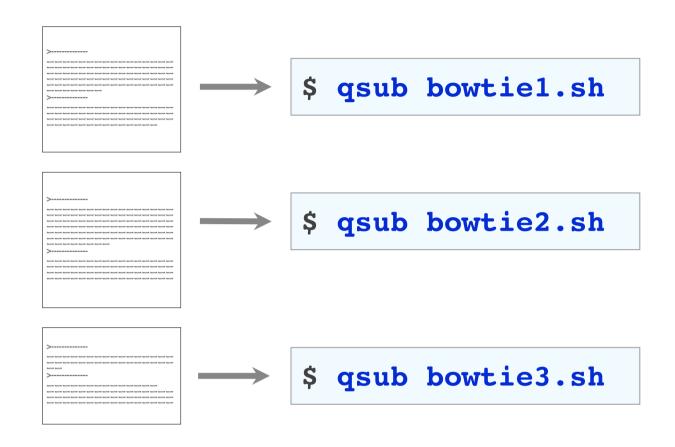
オプション	説明				
#\$ -o filename	標準出力の結果を指定したファイルに保存				
#\$ -e filename	標準エラー出力の結果を指定したファイルに保存				
#\$ -q queue_name	キューを指定してジョブを実行				
#\$ -cwd	qsubした時のディレクトリに移動してジョブを実行				
#\$ -v 環境変数	環境変数をジョブに渡す				
#\$ -N job_name	ジョブ名を指定する				
#\$ -s shell_name	ジョブスクリプトを指定したシェルで実行				
#\$ -a MMDDhhmm	ジョブの開始日時を指定				
#\$ -I resource_name 値	ジョブが使うリソース量を指定する				
<b>#\$ -pe</b> PE_name プロセス数	並列ジョブを実行する場合の環境と並列数の指定				
#\$ -t 開始番号-終了番号	アレイジョブを実行				

#### 当システムにおける キュー(ジョブの待ち行列)構成

	分散並列処理型			共有メモリ型		
	分散処理計算機クラスタ			共有メモリ型計算サーバ		
キュー名	small	medium	large	smps	smpm	smpl
ジョブの特徴	短時間・並列多	中規模	長時間	中メモリ	大メモリ	最大メモリ
利用ノード	node01-40	node01-40	node01-40	ldas-smp	ldas-smp	ldas-smp
最大実行時間/job	6時間	72時間	no limit	no limit	no limit	no limit
最大ジョブ数/キュ	580	200	20	8	4	1
最大使用メモリ/ジョブ	4GB	4GB	4GB	500GB	1TB	4TB
利用できるPE	smp, mpi128, mpi256, make	smp, mpi128, mpi256, make	smp, mpi128, make	smp	smp	smp

- ・キューを指定しない場合、デフォルトでは「small」で実行されます
- ・ユーザあたりジョブ同時実行数は最大 400 です
- 今回の講習では特別キュー「gitc」を使っています。講義中しか使えません

## 並列化



- 1台では時間がかかる計算も、分割して複数台、複数CPUに仕事を させれば数倍の速度で終わる
- 一つのスクリプトに複数の処理を併記しても「同じ計算機上で順次 実行されるだけ」

# 並列実行

emacs で bowtie1.sh を書き換えて、「bowtie2.sh」として保存する
 emacs : 別名で保存(C-x, C-w)

```
$ emacs bowtie1.sh
```

bowtie2.sh

- bowtie2.sh = ecoli.2.fastq をマッピング
- 書き換えたらqsubでSGEに両方を投入し、qstat で実行状況を確認

```
$ qsub bowtie1.sh
$ qsub bowtie2.sh
$ qstat
```

# 結果ファイルの確認

```
$ cd results
$ 1s
ecoli.sam ecoli.1.sam ecoli.2.sam
$ less ecoli.2.sam
$ cd ..
```

## アレイジョブ

- ✓ test\_fastq には ecoli.1.fastq ~ ecoli.12.fastq : 12個のfastq ファイルがある
- ✔ 似たようなジョブファイルをいくつも作るのは面倒
  - SGE のオプションである アレイジョブ機能 を使う
  - 1つのスクリプトファイルで複数の独立ジョブを実行させる
  - #\$ -t 開始番号-終了番号 でアレイジョブの数を指定
  - 変数 \${SGE\_TASK\_ID} が自動生成される
  - \${SGE\_TASK\_ID} にアレイジョブ数がセットされ、インクリメント (コンピュータ用語では変数を一つ増やすこと) しながら回数分実行される
  - qsub は1回でよい

# アレイジョブ用のスクリプトを用意

• emacsでbowtie1.shを改造し、bowtie\_all.sh として保存

```
$ emacs bowtie1.sh
```

```
#!/bin/sh
#$ -q gitc
#$ -cwd
#$ -t 1-12

bowtie2 -x genome/ecoli_genome
   -U test_fastq/ecoli.${SGE_TASK_ID}.fastq
   -S results/ecoli.${SGE_TASK_ID}.sam
```

## アレイジョブ実行

実行とジョブの確認

```
$ qsub bowtie_all.sh
  Your job 814953 ("bowtie all.sh") has been submitted
  $ qstat
  job-ID prior name user state submit/start at queue slots ja-task-ID
  6597 0.5050 1job hiroyo r 01/19/2017 18:04:04 gitc@node03.local
  6597 0.5050 1job hiroyo r 01/19/2017 18:04:04 gitc@node06.local 1 2
  6597 0.5050 1job hiroyo r 01/19/2017 18:04:04 gitc@node08.local 1 3
  6597 0.5050 1job hiroyo r 01/19/2017 18:04:04 gitc@node06.local 1 4
  6597 0.5050 ljob hiroyo r
                            01/19/2017 18:04:04 gitc@node08.local
                                                               1 5
                                                                 アレイジョブ
                                              キュー名@実行ホスト名
                                実行開始時間
            ジョブ ジョブ
ジョブ番号
                  オーナー
     優先順位
                     実行ステータス
     (全て同じ)
                     r: running
                     gw: pending
                     Eqw: failed
```

# 結果ファイルの確認

```
$ cd results
$ 1s
ecoli.1.sam ecoli.2.sam ecoli.3.sam ecoli.4.sam
ecoli.5.sam ecoli.6.sam ecoli.7.sam ecoli.8.sam
ecoli.9.sam ecoli.10.sam ecoli.11.sam ecoli.12.sam
$ less ecoli.12.sam
$ cd ...
$ ls bowtie all.*
bowtie all.e814953.1 bowtie all.sh.e814953.2
bowtie_all.sh.e814953.3 bowtie_all.sh.o814953.4
bowtie all.sh.o814953.4 bowtie all.sh.o814953.1
bowtie all.sh.o814953.2 bowtie all.sh.o814953.3
bowtie all.sh.o814953.4 bowtie all.o814953.5
```

• アレイジョブでは、スクリプト名.ジョブ番号.アレイ番号 のログ が作られる

# 演習

アレイジョブ機能を使って、~/data/4\_sge/results 下の12個のsamファイルについて、htseq-count を使って ecoli.gtf にある遺伝子ごとのヒット数をカウントする。結果は、~/data/4\_sge/results/ecoli.1.htseq ~ ecoli.12.htseq に保存しよう。

- スクリプトファイル名は htseq.sh とする
- 遺伝子情報が載った gtf ファイルは ~/data/3\_ngs/ecoli.gtf にある

### 回答

```
htseq.sh

#!/bin/sh

#$ -q gitc

#$ -cwd

#$ -t 1-12

htseq-count results/ecoli.${SGE_TASK_ID}.sam

../3_ngs/ecoli.gtf >
   results/ecoli.${SGE_TASK_ID}.htseq
```

```
$ qsub htseq.sh
Your job 814953 ("htseq.sh") has been submitted
```